Complexidade de Algoritmos

Análise e notação assintótica

Prof. Marcelo de Souza

45RPE – Resolução de Problemas com Estruturas de Dados

Universidade do Estado de Santa Catarina

Conceitos básicos

Um **problema** é caracterizado pela descrição da sua **entrada** e **saída**.

Conceitos básicos

Um **problema** é caracterizado pela descrição da sua **entrada** e **saída**.

Exemplo:

Problema da ordenação (não decrescente)

Entrada: uma sequência $\langle a_1, a_2, \ldots, a_n \rangle$ de n números.

Saída: uma permutação dos números $\langle a'_1, a'_2, \ldots, a'_n \rangle$ tal que $a'_1 \leq a'_2 \leq \ldots \leq a'_n$.

Conceitos básicos

Um **problema** é caracterizado pela descrição da sua **entrada** e **saída**.

Exemplo:

Problema da ordenação (não decrescente)

Entrada: uma sequência $\langle a_1, a_2, \ldots, a_n \rangle$ de n números.

Saída: uma permutação dos números $\langle a'_1, a'_2, \ldots, a'_n \rangle$ tal que $a'_1 \leq a'_2 \leq \ldots \leq a'_n$.

Exemplo concreto do problema da ordenação

Entrada: 7 8 1 4 6 3 9 → **instância**

Saída: 1 3 4 6 7 8 9 → **solução**/**resultado**

Conceitos básicos

Dado um problema:

- Como saber se um algoritmo é bom para resolvê-lo?
- Como saber qual é o melhor algoritmo entre duas opções?

Conceitos básicos

Dado um problema:

- Como saber se um algoritmo é bom para resolvê-lo?
- Como saber qual é o melhor algoritmo entre duas opções?

Qual medida usar para definir **bom** ou **melhor**?

- Correção;
- Simplicidade;
- Facilidade em codificar;
- Facilidade em manter;
- Tempo de processamento;
- Consumo de memória.

Conceitos básicos

Dado um problema:

- Como saber se um algoritmo é bom para resolvê-lo?
- Como saber qual é o melhor algoritmo entre duas opções?

Qual medida usar para definir **bom** ou **melhor**?

- Correção;
- Simplicidade;
- Facilidade em codificar;
- Facilidade em manter;
- **Tempo de processamento**;
- **Consumo de memória**.

Análise de algoritmos (complexidade)

Como medir a complexidade de um algoritmo?

Análise de algoritmos

Como medir a complexidade?

Podemos executar o(s) algoritmo(s) e medir/plotar os resultados. Problemas:

- Sensível às entradas escolhidas, ao *software* e ao *hardware* usados;
- Comparação prejudicada;
- Necessário implementar e executar todos os algoritmos.

Análise de algoritmos

Como medir a complexidade?

Podemos executar o(s) algoritmo(s) e medir/plotar os resultados. Problemas:

- Sensível às entradas escolhidas, ao *software* e ao *hardware* usados;
- Comparação prejudicada;
- Necessário implementar e executar todos os algoritmos.

Solução: métodos analíticos.

- Definem a complexidade como uma função $f(n)$ do tamanho n da entrada.

Análise de algoritmos

Como medir a complexidade?

Podemos executar o(s) algoritmo(s) e medir/plotar os resultados. Problemas:

- Sensível às entradas escolhidas, ao *software* e ao *hardware* usados;
- Comparação prejudicada;
- Necessário implementar e executar todos os algoritmos.

Solução: métodos analíticos.

- Definem a complexidade como uma função $f(n)$ do tamanho n da entrada.

Ideia geral (complexidade de tempo):

- Contar o número de operações primitivas executadas pelo algoritmo;
- Cada operação primitiva executa em um tempo constante;
- Quanto menor o número de operações, mais eficiente é o algoritmo.

Análise de algoritmos

Operações primitivas

Operações primitivas são passos básicos do algoritmo

- Atribuição de valores;
- Operações aritméticas ou lógicas;
- Comparação de valores;
- Acesso a um elemento de um vetor;
- Recuperar a referência de um objeto;
- Chamada de um método;
- Retorno de um método.

Exemplos

```
int a = 10;
int b = a - 7
if (b < 5)
int c = v[3];
Object x = this;
this.compute();
return result;
```

Análise de algoritmos

Exemplo

Algoritmo `arrayMax(A, n)`:

```
# Entrada: um vetor A com n ≥ 1 elementos inteiros.
# Saída: o maior elemento de A.

currentMax ← A[0]
for i ← 1 to n - 1 do
  if currentMax < A[i] then
    currentMax ← A[i]

return currentMax
```

Análise de algoritmos

Exemplo

Algoritmo `arrayMax(A, n)`:

```
1  # Entrada: um vetor A com n ≥ 1 elementos inteiros.
2  # Saída: o maior elemento de A.
3
4  currentMax ← A[0]
5  for i ← 1 to n - 1 do
6    if currentMax < A[i] then
7      currentMax ← A[i]
8
9  return currentMax
```

Linha	Operações	
4	1 acesso ao vetor + 1 atribuição	2
5	1 inicialização + n comparações + $2(n-1)$ incrementos	$3n-1$
6	1 acesso ao vetor + 1 comparação, repetidos $n-1$ vezes $\rightarrow 2(n-1)$	$2n-2$
7	0 [cond. nunca satisfeito] a $2(n-1)$ [cond. sempre satisfeito]	$[0, 2n-2]$
9	1 retorno	1

Análise de algoritmos

Exemplo

Complexidade de tempo no **melhor caso** (`A[0]` é o maior elemento):

- $T(n) = 2 + 3n - 1 + 2n - 2 + 1 = 5n$.

Complexidade de tempo no **pior caso** (`A[n - 1]` é o maior elemento):

- $T(n) = 2 + 3n - 1 + 2n - 2 + 2n - 2 + 1 = 7n - 2$.

Complexidade de tempo no **caso médio**:

- Depende da distribuição das entradas e do uso de teoria de probabilidades.

Análise de algoritmos

Exemplo

Complexidade de tempo no **melhor caso** (`A[0]` é o maior elemento):

- $T(n) = 2 + 3n - 1 + 2n - 2 + 1 = 5n$.

Complexidade de tempo no **pior caso** (`A[n - 1]` é o maior elemento):

- $T(n) = 2 + 3n - 1 + 2n - 2 + 2n - 2 + 1 = 7n - 2$.

Complexidade de tempo no **caso médio**:

- Depende da distribuição das entradas e do uso de teoria de probabilidades.

Normalmente se considera a complexidade no **pior caso**, pois fornece um limite superior do tempo de execução. Logo:

- O algoritmo `arrayMax` executará no máximo $7n - 2$ operações para cumprir sua tarefa;
- Seja a o tempo gasto na operação primitiva mais complexa sob determinados *hardware* e *software*, o tempo de execução do algoritmo `arrayMax` será de, no máximo, $a(7n - 2)$.

Análise de algoritmos

Taxa de crescimento

Note que $T(n) = 7n - 2$ é uma função linear.

- O tempo de processamento cresce na mesma proporção do tamanho da entrada (n);
- A complexidade tempo desse algoritmo é **linear**.

Análise de algoritmos

Taxa de crescimento

Note que $T(n) = 7n - 2$ é uma função linear.

- O tempo de processamento cresce na mesma proporção do tamanho da entrada (n);
- A complexidade tempo desse algoritmo é **linear**.

A complexidade $T(n)$ pode ser definida por funções com diferentes taxas de crescimento:

- constante ≈ 1
- logarítmica $\approx \log n$
- linear $\approx n$
- n-log-n $\approx n \log n$
- quadrática $\approx n^2$
- cúbica $\approx n^3$
- polinomial $\approx n^k$
- exponencial $\approx a^n \quad (a > 1)$

Análise de algoritmos

Taxa de crescimento das funções de complexidade

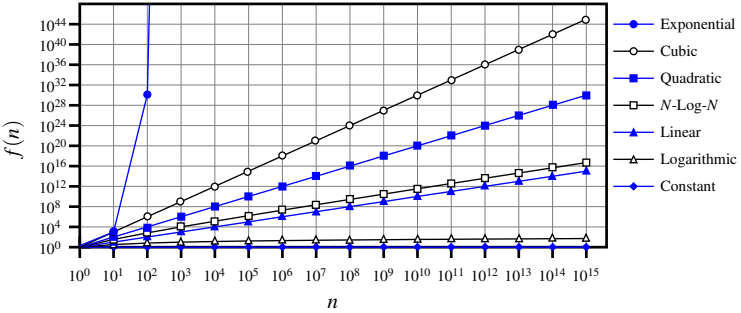

Análise de algoritmos

Taxa de crescimento das funções de complexidade

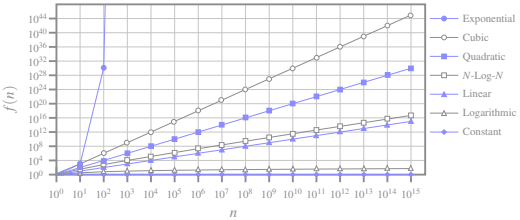

Número de operações

n	$\log n$	n	$n \log n$	n^2	n^3	2^n
8	3	8	24	64	512	256
16	4	16	64	256	4 096	65 536
32	5	32	160	1 024	32 768	$4{,}3 \times 10^9$
64	6	64	384	4 096	262 144	$1{,}8 \times 10^{19}$
128	7	128	896	16384	$2{,}1 \times 10^6$	$3{,}4 \times 10^{38}$
256	8	256	2 048	65 536	$1{,}7 \times 10^7$	$1{,}2 \times 10^{77}$
512	9	512	4 608	262 144	$1{,}3 \times 10^8$	$1{,}3 \times 10^{154}$

Análise de algoritmos

Taxa de crescimento das funções de complexidade

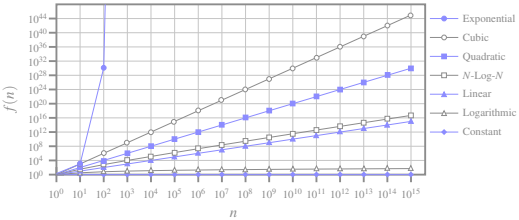

Número de operações

n	$\log n$	n	$n \log n$	n^2	n^3	2^n
8	3	8	24	64	512	256
16	4	16	64	256	4 096	65 536
32	5	32	160	1 024	32 768	$4{,}3 \times 10^9$
64	6	64	384	4 096	262 144	$1{,}8 \times 10^{19}$
128	7	128	896	16384	$2{,}1 \times 10^6$	$3{,}4 \times 10^{38}$
256	8	256	2 048	65 536	$1{,}7 \times 10^7$	$1{,}2 \times 10^{77}$
512	9	512	4 608	262 144	$1{,}3 \times 10^8$	$1{,}3 \times 10^{154}$

Tempo de processamento

n	$\log n$	n	$n \log n$	n^2	n^3	2^n
100	< 1s	< 1s	< 1s	< 1s	< 1s	10^{13} anos
1000	< 1s	< 1s	< 1s	< 1s	1s	10^{284} anos
10000	< 1s	< 1s	< 1s	< 1s	16 min	10^{2993} anos
100000	< 1s	< 1s	< 1s	10 s	12 dias	–
1000000	< 1s	< 1s	< 1s	16 min	32 anos	–

Análise de algoritmos

Taxa de crescimento das funções de complexidade

Exemplo: em um jogo existem 70 itens para compra (e.g., materiais, poderes e armas). Cada item tem um custo e fornece algum benefício. Itens combinados fornecem benefícios diferenciados. A fim de tomar a melhor decisão possível, queremos avaliar toda combinação possível de compra de itens, verificando o custo total e os benefícios esperados.

- Podemos representar uma compra usando um vetor binário $V \in \{0, 1\}^{70}$, onde o valor de uma posição $i \in [0, 70]$ indica se o item i será comprado ou não.
- Devemos avaliar toda combinação possível de valores a V.

Análise de algoritmos

Taxa de crescimento das funções de complexidade

Exemplo: em um jogo existem 70 itens para compra (e.g., materiais, poderes e armas). Cada item tem um custo e fornece algum benefício. Itens combinados fornecem benefícios diferenciados. A fim de tomar a melhor decisão possível, queremos avaliar toda combinação possível de compra de itens, verificando o custo total e os benefícios esperados.

- Podemos representar uma compra usando um vetor binário $V \in \{0, 1\}^{70}$, onde o valor de uma posição $i \in [0, 70]$ indica se o item i será comprado ou não.
- Devemos avaliar toda combinação possível de valores a V.

Resultado: o algoritmo de avaliação terá complexidade de tempo **exponencial** $\rightarrow 2^n$.

Análise de algoritmos

Taxa de crescimento das funções de complexidade

Um algoritmo com complexidade 2^n, para $n = 70$, executando em um computador capaz de processar 10^9 operações por segundo, demoraria 37 436 anos para terminar sua execução!

Análise de algoritmos

Taxa de crescimento das funções de complexidade

Um algoritmo com complexidade 2^n, para $n = 70$, executando em um computador capaz de processar 10^9 operações por segundo, demoraria 37 436 anos para terminar sua execução!

E se usarmos um computador mais rápido?

- 100× mais rápido → 374 anos;
- 1 000× mais rápido → 37 anos;
- 1 000 000× mais rápido → 136 dias;
- 100 000 000× mais rápido → 1 dia.
  - Para $n = 80$, demoraria 140 dias;
  - Para $n = 100$, demoraria 401 969 anos.

Análise de algoritmos

Taxa de crescimento das funções de complexidade

Um algoritmo com complexidade 2^n, para $n = 70$, executando em um computador capaz de processar 10^9 operações por segundo, demoraria 37 436 anos para terminar sua execução!

E se usarmos um computador mais rápido?

- 100× mais rápido → 374 anos;
- 1 000× mais rápido → 37 anos;
- 1 000 000× mais rápido → 136 dias;
- 100 000 000× mais rápido → 1 dia.
  - Para $n = 80$, demoraria 140 dias;
  - Para $n = 100$, demoraria 401 969 anos.

Moral da história

Um algoritmo melhor executando em um computador mais lento **ganhará sempre** de um algoritmo pior em um computador mais rápido, para instâncias suficientemente grandes.

Análise assintótica

A análise completa (contagem de operações) é muito detalhada e onerosa.

Análise assintótica

A análise completa (contagem de operações) é muito detalhada e onerosa.

Além disso, o que importa na prática é a **taxa de crescimento** da função de complexidade!

Análise assintótica

A análise completa (contagem de operações) é muito detalhada e onerosa.

Além disso, o que importa na prática é a **taxa de crescimento** da função de complexidade!

A **análise assintótica** foca em descrever a taxa de crescimento da complexidade de um algoritmo em função do tamanho n da entrada.

Análise assintótica

A análise completa (contagem de operações) é muito detalhada e onerosa.

Além disso, o que importa na prática é a **taxa de crescimento** da função de complexidade!

A **análise assintótica** foca em descrever a taxa de crescimento da complexidade de um algoritmo em função do tamanho n da entrada.

Para isso, usaremos a notação $\mathcal{O}$ (*big-oh*).

- Bem como as notações Θ e Ω.

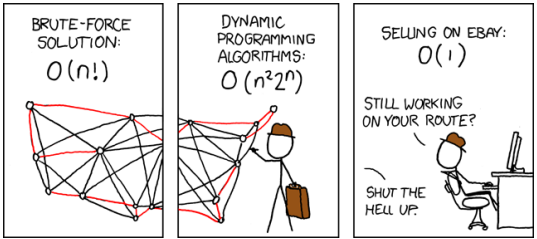

Análise assintótica

Exemplo concreto

Qual a complexidade assintótica do algoritmo `arrayMax`?

```
# Entrada: um vetor A com n ≥ 1 elementos inteiros.
# Saída: o maior elemento de A.

currentMax ← A[0]
for i ← 1 to n - 1 do
  if currentMax < A[i] then
    currentMax ← A[i]

return currentMax
```

Análise assintótica

Exemplo concreto

Qual a complexidade assintótica do algoritmo `arrayMax`?

```
# Entrada: um vetor A com n ≥ 1 elementos inteiros.
# Saída: o maior elemento de A.

currentMax ← A[0]
for i ← 1 to n - 1 do
  if currentMax < A[i] then
    currentMax ← A[i]

return currentMax
```

Sabemos que, no pior caso, são executadas $7n - 2$ operações. Logo, esse algoritmo tem complexidade $\mathcal{O}(n)$. Isto é, complexidade linear.

- Não precisamos contar todas as operações. Basta identificarmos o termo de maior complexidade (neste caso, n), pois é quem define a taxa de crescimento da função!

Análise assintótica

Exemplo I

Algoritmo `sum_numbers(n1, n2)`:

```
# Soma dois números inteiros.
def sum_numbers(n1, n2):
  result = n1 + n2
  return result
}
```

Análise assintótica

Exemplo I

Algoritmo `sum_numbers(n1, n2)`:

```
1 # Soma dois números inteiros.
2 def sum_numbers(n1, n2):
3   result = n1 + n2
4   return result
5 }
```

Análise:

- Linhas 3 e 4 executam operações de tempo constante;
- Complexidade **constante**: $\mathcal{O}(1)$;
- Algoritmo de tempo constante.

Análise assintótica

Exemplo II

Algoritmo `disjoint1(vA, vB, vC)`:

```
# Retorna true se não existe nenhum elemento comum nos três grupos.
# Cada vetor possui elementos distintos dentro de si.
def disjoint1(vA, vB, vC):
  for a in vA:
    for b in vB:
      for c in vC:
        if a == b and b == c:
          return False
  return True
```

Análise assintótica

Exemplo II

Algoritmo `disjoint1(vA, vB, vC)`:

```
1  # Retorna true se não existe nenhum elemento comum nos três grupos.
2  # Cada vetor possui elementos distintos dentro de si.
3  def disjoint1(vA, vB, vC):
4    for a in vA:
5      for b in vB:
6        for c in vC:
7          if a == b and b == c:
8            return False
9    return True
```

Análise:

- A operação constante da linha 7 é repetida $n \times n \times n = n^3$ vezes;
- Complexidade **cúbica**: $\mathcal{O}(n^3)$;
- Algoritmo de tempo cúbico.

Análise assintótica

Exemplo III

Algoritmo `disjoint2(vA, vB, vC)`:

```
# Retorna true se não existe nenhum elemento comum nos três grupos.
# Cada vetor possui elementos distintos dentro de si.
def disjoint2(vA, vB, vC):
  for a in vA:
    for b in vB:
      if a == b:
        for c in vC:
          if a == c:
            return False
  return True
```

Análise assintótica

Exemplo III

Algoritmo `disjoint2(vA, vB, vC)`:

```
1  # Retorna true se não existe nenhum elemento comum nos três grupos.
2  # Cada vetor possui elementos distintos dentro de si.
3  def disjoint2(vA, vB, vC):
4    for a in vA:
5      for b in vB:
6        if a == b:
7          for c in vC:
8            if a == c:
9              return False
10   return True
```

Análise:

- Os laços das linhas 4 e 5 sempre são executados – $\mathcal{O}(n^2)$;
- No máximo n pares são iguais (lin. 6), então o laço da linha 7 executa no máximo n vezes;
- Complexidade **quadrática**: $\mathcal{O}(n^2)$.

Análise assintótica

Exemplo IV

Algoritmo `repeat(c, n)`:

```
# Compõe uma string com o caractere c repetido n vezes.
def repeat(c, n):
  answer = ''
  for i in range(n):
    answer += c
  return answer
```

Análise assintótica

Exemplo IV

Algoritmo `repeat(c, n)`:

```
1 # Compõe uma string com o caractere c repetido n vezes.
2 def repeat(c, n):
3   answer = ''
4   for i in range(n):
5     answer += c
6   return answer
```

Análise:

- Strings são imutáveis em Python: o comando `answer += c` implica em criar uma nova string, copiar cada caractere da string antiga para ela, e acrescentar o caractere c;
- A linha 5 executa operações conforme o tamanho de `answer`: $1 + 2 + \cdots + n - 1$;
- Logo, sua complexidade é $\sum_{i=0}^{n-1} i = n(n+1)/2$;
- Complexidade **quadrática**: $\mathcal{O}(n^2)$.

Análise assintótica

Exemplo V

Algoritmo `unique1(data)`:

```
# Retorna true se não existe elemento duplicado no vetor.
def unique1(data):
  n = len(data)
  for i in range(n - 1):
    for j in range(i + 1, n):
      if data[i] == data[j]:
        return False
  return True
```

Análise assintótica

Exemplo V

Algoritmo `unique1(data)`:

```
# Retorna true se não existe elemento duplicado no vetor.
def unique1(data):
  n = len(data)
  for i in range(n - 1):
    for j in range(i + 1, n):
      if data[i] == data[j]:
        return False
  return True
```

Análise:

- O laço interno é executado $(n-1) + (n-2) + \cdots + 2 + 1$ vezes;
- Complexidade **quadrática**: $\mathcal{O}(n^2)$.

Análise assintótica

Exemplo VI

Algoritmo `unique2(int[] data)`:

```
# Retorna true se não existe elemento duplicado no vetor.
# O vetor é ordenado para verificar apenas elementos subsequentes.
def unique2(data):
  n = len(data)
  data.sort() # Operação em O(n log n)
  for i in range(n - 1):
    if data[i] == data[i + 1]:
      return False
  return True
```

Análise assintótica

Exemplo VI

Algoritmo `unique2(int[] data)`:

```
# Retorna true se não existe elemento duplicado no vetor.
# O vetor é ordenado para verificar apenas elementos subsequentes.
def unique2(data):
  n = len(data)
  data.sort() # Operação em O(n log n)
  for i in range(n - 1):
    if data[i] == data[i + 1]:
      return False
  return True
```

Análise:

- A ordenação custa $n \log n$ e percorrer o vetor custa n;
- Complexidade **n log n**: $n \log n + n \iff \mathcal{O}(n \log n)$.

Apêndices

Apêndice I

Definição formal da notação $\mathcal{O}$

Sejam $f(n)$ e $g(n)$ funções que mapeiam o tamanho da entrada no tempo de processamento, dizemos que $f(n)$ é $\mathcal{O}(g(n))$ se existe uma constante real $c > 0$ e uma constante inteira $n_0 \geq 1$ tais que $f(n) \leq cg(n)$ para todo inteiro $n \geq n_0$.

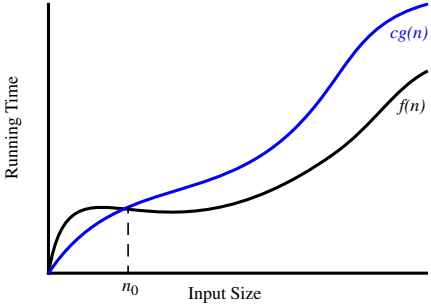

Apêndice I

Definição formal da notação $\mathcal{O}$

Sejam $f(n)$ e $g(n)$ funções que mapeiam o tamanho da entrada no tempo de processamento, dizemos que $f(n)$ é $\mathcal{O}(g(n))$ se existe uma constante real $c > 0$ e uma constante inteira $n_0 \geq 1$ tais que $f(n) \leq cg(n)$ para todo inteiro $n \geq n_0$.

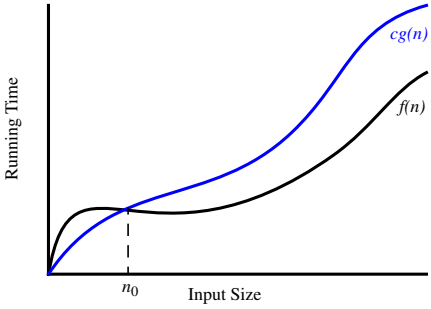

Na prática:

- Se $f(n)$ é $\mathcal{O}(g(n))$, então $f(n)$ é "menor ou igual" a $g(n)$ a medida que n cresce.
- Com isso, $g(n)$ é um limite superior para $f(n)$.
- Ou seja, $f(n)$ é tão boa quando $g(n)$.

Apêndice I

Definição formal da notação $\mathcal{O}$

Sejam $f(n)$ e $g(n)$ funções que mapeiam o tamanho da entrada no tempo de processamento, dizemos que $f(n)$ é $\mathcal{O}(g(n))$ se existe uma constante real $c > 0$ e uma constante inteira $n_0 \geq 1$ tais que $f(n) \leq cg(n)$ para todo inteiro $n \geq n_0$.

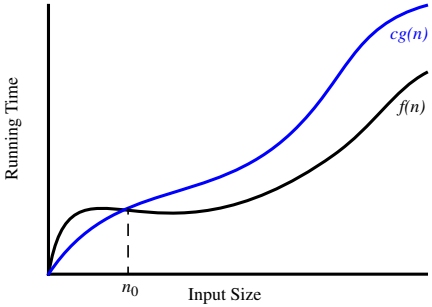

Na prática:

- Se $f(n)$ é $\mathcal{O}(g(n))$, então $f(n)$ é "menor ou igual" a $g(n)$ a medida que n cresce.
- Com isso, $g(n)$ é um limite superior para $f(n)$.
- Ou seja, $f(n)$ é tão boa quando $g(n)$.

Exemplo: a função $T(n) = 7n - 2$ é $\mathcal{O}(n)$.

- Para $c = 7$ e $n_0 = 1$, temos que $7n - 2 \leq cn$, para todo $n \geq n_0$. Logo $T(n)$ é $\mathcal{O}(n)$.

Apêndice II

Notações $\mathcal{O}$, Θ e Ω

Notação $\mathcal{O}$ (majorante)

Se $f(n)$ é $\mathcal{O}(g(n))$, então $cg(n)$ é um **limite superior** para $f(n)$. Ou seja, $f(n)$ **não é pior** que $cg(n)$.

Apêndice II

Notações $\mathcal{O}$, Θ e Ω

Notação $\mathcal{O}$ (majorante)

Se $f(n)$ é $\mathcal{O}(g(n))$, então $cg(n)$ é um **limite superior** para $f(n)$. Ou seja, $f(n)$ **não é pior** que $cg(n)$.

Notação Ω (minorante)

Se $f(n)$ é $\Omega(g(n))$, então $cg(n)$ é um **limite inferior** para $f(n)$. Ou seja, $f(n)$ **não é melhor** que $cg(n)$.

Apêndice II

Notações $\mathcal{O}$, Θ e Ω

Notação $\mathcal{O}$ (majorante)

Se $f(n)$ é $\mathcal{O}(g(n))$, então $cg(n)$ é um **limite superior** para $f(n)$. Ou seja, $f(n)$ **não é pior** que $cg(n)$.

Notação Ω (minorante)

Se $f(n)$ é $\Omega(g(n))$, então $cg(n)$ é um **limite inferior** para $f(n)$. Ou seja, $f(n)$ **não é melhor** que $cg(n)$.

Notação Θ (limite "apertado" – majorante e minorante)

Se $f(n)$ é $\Theta(g(n))$, então $c_1 g(n)$ é um **limite inferior** para $f(n)$ e $c_2 g(n)$ é um **limite superior** para $f(n)$. Ou seja, $f(n)$ **é igual** a $cg(n)$.

Apêndice III

Notações e suas relações

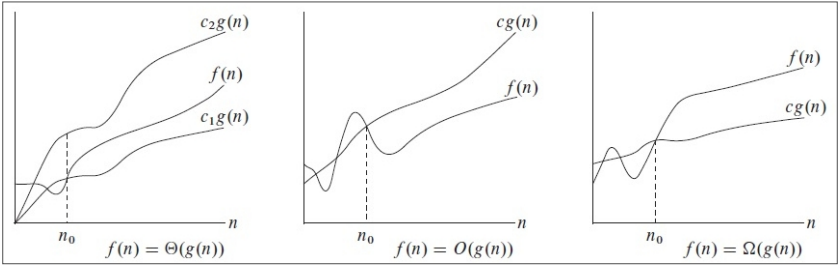

Detalhes:

- $f(n)$ é $\Theta(g(n)) \iff f(n)$ é $\mathcal{O}(g(n))$ e $f(n)$ é $\Omega(g(n))$.
- $f(n)$ é $\Theta(g(n)) \iff g(n)$ é $\Theta(f(n))$.
- $f(n)$ é $\mathcal{O}(g(n)) \iff g(n)$ é $\Omega(f(n))$.

45RPE – Resolução de Problemas com Estruturas de Dados
Prof. Marcelo de Souza